

RTF · VIBEVOICE 0.5B

~~5,39~~

0,885

6,1x más rápido.

La misma CPU. Sin GPU. Sin nube.


RTF < 1 = más rápido que el tiempo real

Cinco cambios. La misma CPU.

CAMBIO · RTF

GANANCIA

Punto de partida

 5,39 fp32 · 20 pasos

Cuantización int8 dinámica

1,96×

 2,75

PyTorch · pesos a ½

6 pasos de difusión, no 20

1,26×

 2,18

DPM-Solver multipaso

Motor OpenVINO

2,00×

 1,09

grafos compilados

Decodificador sin conv. traspuesta

1,11×

 0,98

k = 2s → producto de matrices

Bucle de difusión en un solo grafo

1,06×

 0,885

6 pasos + guía + solver, 1 llamada

 más lento que el tiempo real  más rápido

Lo que **no** entró en la tabla.

Cada idea, contra una meta escrita **antes** de medir.

La iGPU del propio i7

la meta pedía -7 %

-6,1 %

LM en int8 en vez de int4

más lento y no suena mejor

+9 %

Dos pasadas del LM en paralelo

la meta pedía -20 %

-7 %

Enseñar a la VM su topología SMT

ruido

+0,6 %

torch.compile

nada

1,00×

Todo medido. Todo documentado.